# Lecture materials on system software development

Zhmylev Sergei

Autumn 2019

УНИВЕРСИТЕТ ИТМО

# Course structure I

- System software
- Software interface
- Code structure
- Code compilation
- Error code
- A role of the OS
- OS booting process
- Syscalls

# Course structure II

- Calling the OS
- File
- File descriptor
- I/O streams of a process
- Standard I/O streams
- open(2)
- Common access modes
- lseek(2)

# Course structure III

- read(2)
- write(2)
- close(2)
- dup(2) и dup2(2)
- stat(2)
- Ошибки в системных вызовах
- Стандартизация ошибок
- Пример ошибки

# Course structure IV

- Заголовочные файлы
- Пример чтения/записи
- Makefile
- Утилита make
- Полезные функции
- Ввод-вывод со смещением
- Рассеянный ввод-вывод
- Структура iovec (I/O vector)

# Course structure V

- Сброс кешей
- Работа с файловыми дескрипторами
- Команды fcntl(2)
- Проверка доступа
- Изменение прав доступа
- Изменение владельца
- Маска создания файла
- Работа с ссылками

# Course structure VI

- Символьные ссылки
- Работа с каталогами
- Рабочая директория
- Чтение каталогов
- Структура dirent
- Файлы устройств
- Модель памяти процесса
- Выделение памяти

# Course structure VII

Утилита pmap(1)

Процесс

Состояния процесса

# Useful links

http://src.illumos.org/

https://github.com/mit-pdos/xv6-public

https://se.ifmo.ru/~korg/

https://vk.com/korglings

Books :

1. Uresh Vahalia. UNIX Internals
2. A. S. Tanenbaum, A. S. Woodhull. Operating Systems: Design and Implementation

# System software

- System software languages
- Syscalls
- I/O
- Threads and processes

# Software interface

Each program receives arguments and environment variables

Error code is an integer describing the correctness of program termination

# Code structure

```
int main(
    int argc,
    char *argv[],
    char *envp[]
) {
    /* ... */

    return 0;
}
```

# Code structure

```
#include <stdlib.h>

int main(
    int argc,
    char *argv[],
    char *envp[]
) {
    /* ... */

    return EXIT_SUCCES;
}
```

# Code compilation

```
# gcc -c program.c
# gcc -o program program.o

# gcc -o program program.c

# cc -o program program.c
```

# Error code

```
# rm -f /etc/passwd 2<&-
# echo $?
1
# echo Hello, world!
Hello, world!
# echo $?
0
```

# A popular mistake

Using void main() is inappropriate!

```
# cat void.c
void main(void) {}
# ./void
# echo $?
16
```

# A role of the OS

- Multitasking;
- Memory virtualization;
- Device management;
- Interrupt handling;
- Extending the available set of application-level operations.

# OS booting process

- Reset vector: UEFI, BIOS, . . .
- I/O, *PIC(IRQ), VGA
- POST + PCI BIOS
- Boot device detection
- Bootloader stage0 (boot sector)
- Bootloader stage1
- OS kernel

# Syscalls

- Kernel functions calling
- Using hardware via the common API
- Have libc interfaces
- Have kernel privileges

# Calling the OS

```
/* program termination with errcode 2 */
_exit(2);
```

```
.globl _start
_start:
pushq $2
movq $1, %rax
int $0x80
```

```
# cc -m64 -Wall -Wextra -Wno-comment \
   -nostdlib -o main main.S
```

https://pastebin.com/knTdpZRe

What is a file?

Everything is a file!

*Apart from threads and the kernel*

# File descriptor

```
http:
//src.illumos.org/source/xref/illumos-gate/
usr/src/uts/common/syscall/open.c#54

http://src.illumos.org/source/xref/
illumos-gate/usr/src/uts/common/fs/vnode.c#940
```

- A file descriptor number is a positive integer that abstracts processes from files they are using.

# I/O streams of a process

| Number | File | Flags |
|---|---|---|
| 0 | /dev/tty | O_RDWR \| O_LARGEFILE |
| 1 | /dev/tty | O_RDWR \| O_LARGEFILE |
| 2 | /dev/tty | O_RDWR \| O_LARGEFILE |
| 3 | /etc/passwd | O_RDONLY |
| 4 | /dev/mtdblock3 | O_RDWR |
| ... | ... | ... |
| 255 | ... | ... |

# Standard I/O streams

```
# grep FILENO /usr/include/unistd.h
#define STDIN_FILENO 0
#define STDOUT_FILENO 1
#define STDERR_FILENO 2
```

# open(2)

```
int open(
    const char *path,  /* file path */
    int oflag,         /* access mode */
    /* mode_t mode */ /* access rights */
);
```

Returns a file descriptor number or an error code

# Common access modes

O_RDONLY – Read-only

O_WRONLY – Write-only

O_RDWR – Read-write

O_CREAT – Create if not exists

O_APPEND – Append to the end of the file

O_TRUNC – Write from the beginning of the file

O_LARGEFILE – Long file position

O_EXCL – Long file position

# lseek(2)

```
off_t lseek(
   int fildes, /* номер открытого файла */
   off_t offset,    /* смещение позиции */
   int whence                  /* действие */
);
```

Returns an updated offset in bytes or an error code

# read(2)

```
ssize_t read(
   int fildes, /* номер открытого файла */
   void *buf,              /* буфер чтения */
   size_t nbyte        /* количество байт */
);
```

Returns the amount of bytes read successfully or an error code

# write(2)

```
ssize_t write(
   int fildes, /* номер дескриптора */
   const void *buf, /* буфер записи */
   size_t nbyte  /* количество байт */
);
```

Returns the amount of bytes written successfully or an error code

# close(2)

```
int close(
   int fildes, /* номер дескриптора */
);
```

Returns zero or an error code

# dup(2) и dup2(2)

```
int dup(
   int fildes /* номер открытого файла */
);
int dup2(int fildes, int fildes2);
```

Функция возвращает номер нового дескриптора или код ошибки

# stat(2)

```
int stat(
   const char *restrict path,
      /* путь к файлу*/
   struct stat *restrict buf
      /* результат */
);
```

Функция возвращает номер 0 или код ошибки

# Ошибки в системных вызовах

Код возврата системного вызова:

- меньше 0 – ошибка в ходе выполнения вызова
- равен 0 – успешное выполнение
- больше 0 – результат успешного выполнения

# Стандартизация ошибок

- Унификация ошибочных кодов
- Переменная `errno`
- Функция `perror(3)`
- Функция `strerror(3)`

# Пример ошибки

```
if (read(7, buf, 1) < 0) {
    fprintf(stderr, "%d␣", errno);
    perror("read");
    _exit(1);
}

/* 9 read: Bad file number */
```

# Заголовочные файлы

- unistd.h – объявления UNIX
- stdio.h – стандартный ввод/вывод
- fcntl.h – операции с файлами
- sys/types.h – системные типы
- sys/stat.h – системные статусы

# Пример чтения/записи

```
#include <unistd.h>
int main(int argc, char *argv[]) {
    int bytes;
    char buf[256];
    while((bytes = read(STDIN_FILENO, buf,
    ↪  sizeof(buf))) > 0) {
        if (write(STDERR_FILENO, buf, bytes)
    ↪    < 0) {
            return 1;
        }
    }

    return bytes;
}
```

# Makefile

```
PROJS=main
CC=gcc
CFLAGS=-m64

all: $(PROJS)
	@echo Done!

$(PROJS):
	$(CC) $(CFLAGS) -o $@ $(@:=.c)
```

# Утилита make

```
# make
gcc -m64 -o main main.c
Done!
# ./main
Hello, world!
```

# Полезные функции

- isatty(3C)
- gethostbyname(3NSL)
  gethostbyaddr(3NSL)
- htons(3SOCKET)
  htonl(3SOCKET)
  ntohs(3SOCKET)
  ntohl(3SOCKET)
- usleep(3C)

# Ввод-вывод со смещением

```
ssize_t pread(int fildes, void *buf,
   ↪  size_t nbyte, off_t offset);

ssize_t pwrite(int fildes, const void *buf
   ↪  , size_t nbyte, off_t offset);
```

Функции возвращают количество байт или код ошибки

# Рассеянный ввод-вывод

```
ssize_t readv(
   int fildes,   /* дескриптор файла */
   const struct iovec *iov,
                  /* массив структур */
   int iovcnt /* количество структур */
);
```

Функция возвращает количество байт или код ошибки

# Структура iovec (I/O vector)

```
#include <sys/uio.h>
typedef struct iovec {
void *iov_base;
/* start address */
size_t iov_len;
/* segment length */
} iovec_t;
```

# Сброс кешей

```
void sync(
   void /* не принимает аргументов */
);
```

Код возврата функции не информативен

# Работа с файловыми дескрипторами

```
int fcntl(
   int fildes,                  /* дескриптор */
   int cmd,                        /* команда */
   ... /* переменное число аргументов */
);
```

Код возврата функции интерпретируется в зависимости от команды

# Команды fcntl(2)

| | |
|---|---|
| F_DUPFD / F_DUP2FD | аналог dup/dup2 |
| F_FREESP | освободить место |
| F_GETFD / F_SETFD | флаг close on exec |
| F_GETFL / F_SETFL | флаги доступа |
| F_GETLK / F_SETLK<br>F_GETLKW / F_SETLKW | блокировка файла |

F_RDLCK / F_WRLCK / F_UNLCK

# Проверка доступа

```
int access(const char *path, int amode);
```

R_OK – чтение
W_OK – запись
X_OK – исполнение
F_OK – существование

Функция возвращает 0 или код ошибки

# Изменение прав доступа

```
int chmod(const char *path, mode_t mode);
int fchmod(int fildes, mode_t mode);
```

S_ISUID 04000
S_IRWXU 00700
(S_ISUID | S_URWXU) 04700

Функции возвращают 0 или код ошибки

# Изменение владельца

```
int chown(
    const char *path,
    uid_t owner,
    gid_t group
);
int fchown(
    int fildes,
    uid_t owner,
    gid_t group
);
```

Функции возвращают 0 или код ошибки

# Маска создания файла

```
mode_t umask(
    mode_t cmask        /* значение маски */
);
```

Возвращает предыдущее значение маски

Как получить текущее значение?

# Работа с ссылками

```
int link(
   const char *existing, /* путь к файлу*/
   const char *new     /* путь к ссылке */
);
int unlink(const char *path);
```

Функции возвращают 0 или код ошибки

# Символьные ссылки

```
int symlink(
   const char *name1,
   const char *name2
);

ssize_t readlink(
   const char *restrict path, /* ссылка*/
   char  *restrict buf,       /* буфер */
   size_t bufsiz      /* размер буфера */
);
```

# Работа с каталогами

```
int mkdir(
   const char *path, /* путь к каталогу */
   mode_t mode       /* режим доступа */
);
int rmdir(const char *path);
```

Функции возвращают 0 или код ошибки

# Рабочая директория

```
int chdir(const char *path);
int fchdir(int fildes);
```

`getcwd(3)` возвращает указатель на буфер либо -1 и имеет прототип:

```
char *getcwd(char *buf, size_t size);
```

# Чтение каталогов

```
DIR *opendir(const char *dirname);

struct dirent *readdir(DIR *dirp);

void rewinddir(DIR *dirp);

int closedir(DIR *dirp);
```

# Структура dirent

```
typedef struct dirent {
   ino_t d_ino;
      /* номер индексного дескриптора */
   off_t d_off; /* смещение от начала */
   unsigned short reclen;
                        /* длина записи */
   char d_name[];          /* имя файла */
} dirent_t;
```

# Файлы устройств

```
int mknod(
   const char *path,   /* путь к файлу */
   mode_t mode, /* режим доступа и тип */
   dev_t dev                /* устройство */
);
```

Функции возвращают 0 или код ошибки

# Модель памяти процесса

# Выделение памяти

Расширение сегмента данных:

```
int brk(void *endds);
void *sbrk(intptr_t incr);
```

Выделение новых сегментов из анонимной памяти:

```
void *mmap(
    void *addr,
    size_t len,
    int prot,
    int flags,
    int fildes,
    off_t off
);
```

# Утилита pmap(1)

```
helios$ pmap $$
08043000   20K   rw---     [ stack ]
08050000   552K  r-x--     /usr/bin/bash
080E9000   76K   rwx--     /usr/bin/bash
080FC000   300K  rwx--     [ heap ]
FEB20000   64K   rwx--     [ anon ]
FEB40000   56K   r-x--     /lib/module.so
```

# Процесс

Процесс – это совокупность программы и метаинформации, описывающей её выполнение ©KorG

Выполняются параллельно и формально независимы друг от друга

# Состояния процесса

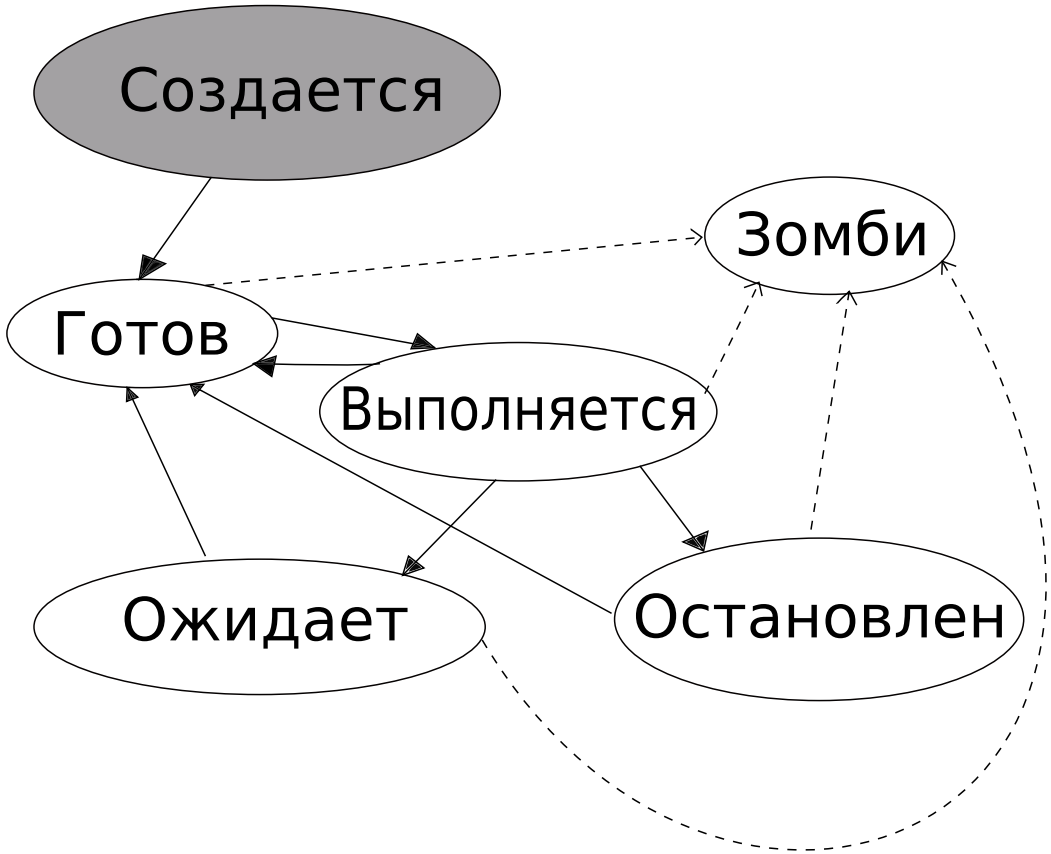

# Благодарности


- Афанасьев Дмитрий Борисович
- Горская Александра Андреевна
- Ховалкина Ксения Николаевна
- Киреев Валерий Юрьевич
- и многие другие...

# Спасибо за внимание

```
# perl '-es!!),-#(-.?{<>-8#=..#<-*}>;*7-86)!;y!#() -?{}!\x20/'-v;<!;s++$_+ee'
```